NeuroAgenda: predicción del riesgo de inasistencia en consulta ambulatoria de psicología, nutrición y fisioterapia

MINE-4101 Ciencia de Datos Aplicada · Proyecto final · Entrega 1 · Octubre 2026 · Equipo: Nombre integrante 1; Nombre integrante 2 · Repositorio: https://github.com/Juliethr3/neuroagenda-minhalma · Video: enlace YouTube

1. Problemática y entendimiento del negocio

Organización. MinHalma, centro de salud ambulatorio de reciente creación que ofrece psicología, nutrición y fisioterapia. **Stakeholder:** nombre y cargo. Por ser un centro nuevo, su historial de citas aún es corto: esto justifica validar el enfoque con un conjunto público (sección 5) y es, a la vez, una oportunidad para estandarizar desde el inicio el registro del estado de cada cita.

Problema. Una de cada cinco citas ambulatorias no se cumple: la tasa promedio de inasistencia (no-show) reportada en 105 estudios es cercana al 23 % (Dantas et al., 2018). En Colombia, el Hospital Regional de San Gil reportó 15.464 citas incumplidas solo en el primer semestre de 2025 (Blu Radio, 2025), y la ECV 2025 del DANE muestra que la proporción de personas con un problema de salud que acudieron a su entidad bajó de 63,3 % a 56,8 % entre 2024 y 2025 (Valora Analitik, 2026). Psicología, nutrición y fisioterapia funcionan por sesiones recurrentes: cada inasistencia es tiempo profesional no facturado, un cupo que otro paciente no pudo usar y una ruptura de la continuidad del tratamiento. Para un centro nuevo, la ocupación de agenda es además una condición de sostenibilidad financiera. Hoy los recordatorios son indiscriminados: se contacta igual a quien siempre asiste que a quien probablemente faltará.

Oportunidad y objetivo. Estimar, al momento de agendar y 72 h antes de la cita, la probabilidad individual de inasistencia para **focalizar las acciones de confirmación y reasignación de cupos** en las citas de mayor riesgo. Objetivos específicos: (O1) construir y validar un modelo calibrado de riesgo; (O2) exponerlo mediante una API REST; (O3) entregar un tablero operativo con la lista priorizada y los KPI.

KPI de negocio	Definición	Meta a 6 meses (propuesta)
Tasa de inasistencia	Citas no asistidas / citas programadas	Reducción relativa ≥ 20 % frente a la línea base
Cupos recuperados	Cupos liberados con antelación y reasignados	≥ 50 % de las cancelaciones anticipadas
Ocupación efectiva	Horas de especialista atendidas / horas ofertadas	+5 p.p.
Eficiencia de contacto	Inasistencias evitadas por cada 100 contactos	Superior a la estrategia de contactar al azar
Equidad	Brecha de recall del modelo entre grupos de edad, sexo y subsidio	≤ 5 p.p.

2. Ideación del producto de datos

Usuarios y dolores. (i) *Coordinación de agenda/call center*: no sabe a quién llamar primero y sobreagenda a ciegas. (ii) *Dirección de MinHalma*: pierde capacidad facturable y no mide el efecto de las estrategias de recordatorio. (iii) *Psicólogos, nutricionistas y fisioterapeutas*: huecos en la agenda y pacientes que interrumpen el plan de sesiones. (iv) *Pacientes*: listas de espera más largas por cupos perdidos.

Componentes (4 de 4): (1) **modelo de ML** de riesgo por cita, calibrado y explicable (SHAP); (2) **API REST** (FastAPI) con endpoints /score y /explain consumidos por el sistema de agendamiento; (3) **dashboard** (Streamlit) con lista priorizada, acción sugerida y KPI; (4) integración opcional con mensajería para recordatorios focalizados. **Requerimientos clave:**

puntaje al agendar y en D-3; latencia < 500 ms por cita; seudonimización y control de acceso por rol; registro de la acción tomada y su desenlace (para medir impacto y reentrenar); monitoreo de calibración y deriva. **Restricción de uso:** el puntaje solo activa acciones de apoyo (confirmar, recordar, reasignar cupos liberados); nunca se usa para negar o postergar una cita.

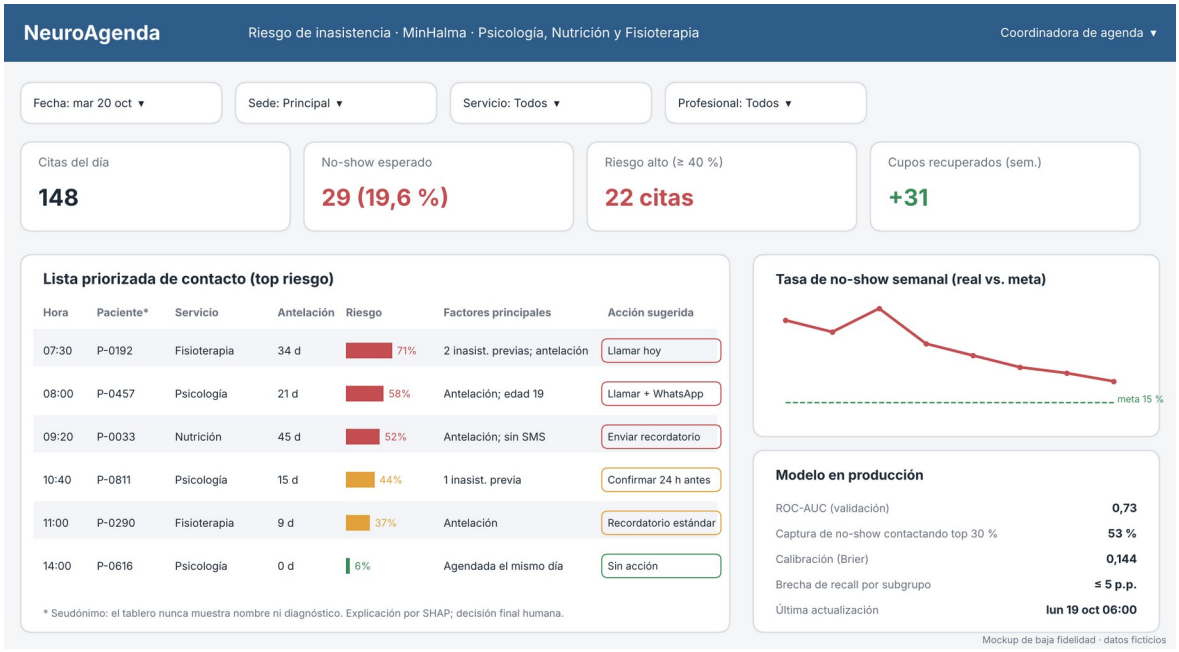


Figura 1. Mockup del tablero operativo de NeuroAgenda (datos ficticios). Fuente: elaboración propia.

3. Aspectos éticos y legales

Riesgo	Marco aplicable	Mitigación en el producto
Datos de salud = datos sensibles	Ley 1581 de 2012 (arts. 5–6) y Decreto 1377 de 2013: autorización previa, expresa e informada y finalidad explícita	Autorización en el aviso de privacidad de MinHalma; minimización (solo variables de agenda); seudonimización en origen
Reserva de historia clínica y secreto profesional (crítico en salud mental)	Resolución 1995 de 1999; Ley 1090 de 2006 (psicología); Ley 528 de 1999 (fisioterapia); Ley 73 de 1979 (nutrición); Ley 1616 de 2013	El modelo no usa diagnósticos ni notas clínicas; el tablero no muestra nombre ni diagnóstico; acceso por rol y auditoría
Interoperabilidad y custodia	Ley 2015 de 2020 (historia clínica electrónica interoperable)	Acuerdo de transferencia y confidencialidad con MinHalma; los datos permanecen en su infraestructura
Sesgo y discriminación algorítmica	CONPES 3975 de 2019 (IA confiable); evidencia de sesgo en algoritmos de salud (Obermeyer et al., 2019)	Variables como subsidio y barrio son proxies socioeconómicos: auditoría de equidad por subgrupo y prohibición de uso restrictivo
Investigación con datos secundarios	Resolución 8430 de 1993 (investigación sin riesgo)	Aval de un comité de ética (el de la universidad, si MinHalma no cuenta con uno) antes de usar datos reales
Transferibilidad del conjunto proxy	Datos públicos y anonimizados (Kaggle); contexto Brasil 2016	Uso solo exploratorio; el modelo final se entrena con datos de MinHalma

4. Enfoque analítico

Pregunta de negocio: ¿a qué citas debe dirigirse la confirmación activa para evitar el mayor número de inasistencias con una capacidad de contacto limitada? Se formula como **clasificación binaria supervisada** (no-show = 1) con desbalance moderado (20,2 %). Hipótesis (estado preliminar según el EDA, sección 6):

Hipótesis	Técnica de contraste	Evidencia preliminar

H1. A mayor antelación entre agendamiento y cita, mayor inasistencia	Mann-Whitney, χ^2, OR ajustado	Soportada: 4,6 % (mismo día) vs. 34,2 % (31–60 d)
H2. El historial de inasistencias del paciente es predictor independiente	Regresión logística, tasas por historial	Soportada: OR = 1,44 [IC 95 %: 1,36–1,52]
H3. El recordatorio SMS reduce la inasistencia una vez ajustado por antelación	OR de Mantel-Haenszel estratificado	Soportada: OR crudo 1,90 → OR MH 0,77
H4. El riesgo varía por edad y nivel socioeconómico (alerta de equidad)	χ^2, V de Cramér, OR ajustados	Soportada: 12–17 años 26,4 % vs. 60–74 15,0 %; subsidio OR = 1,30 [IC 95 %: 1,24–1,37]
H5. Las variables de agenda bastan para priorizar contactos mejor que el azar	Validación cruzada agrupada por paciente	Soportada: ROC-AUC 0,733; contactar el 30 % de mayor riesgo captura 53 % de los no-show

Técnicas (Entrega 2): regresión logística regularizada (línea base interpretable), Random Forest y gradient boosting (LightGBM/XGBoost), que la literatura reporta como los de mejor desempeño en este problema (Salazar et al., 2022), con búsqueda de hiperparámetros; calibración isotónica; explicabilidad con SHAP. **Validación:** GroupKFold por paciente (evita fuga entre citas de una misma persona) y partición temporal (últimas semanas como prueba). **Métricas del modelo:** PR-AUC (principal, por el desbalance), ROC-AUC, recall y precisión en el top-k % (capacidad real de llamadas), Brier y curva de calibración, y brecha de recall entre subgrupos. El umbral se elegirá por costo esperado (costo del contacto vs. valor del cupo recuperado).

5. Recolección de datos

Fuente 1 (disponible, proxy): *Medical Appointment No Shows* (Hoppen, 2016), CSV estructurado de 110.527 citas × 14 atributos de 62.299 pacientes del sistema público de Vitória (Brasil), citas entre 2016-04-29 y 2016-06-08. Permite validar hipótesis y pipeline mientras se formaliza el acceso. **Fuente 2 (Entrega 2):** extracto seudonimizado del sistema de agendamiento de MinHalma (cita, servicio, profesional, hora, canal, estado asistió/canceló/no asistió, edad, sexo, régimen, municipio). **Fuente 3:** calendario de festivos de Colombia. Diccionario completo en el repositorio (docs/diccionario_datos.md); atributos principales:

Atributo (original)	Tipo	Descripción	Relevancia
AppointmentID / PatientId	ID	Identificador de cita / paciente (seudónimo)	Agrupación y historial
ScheduledDay / AppointmentDay	Fecha	Fecha-hora de agendamiento / fecha de la cita (sin hora)	Deriva la antelación (predictor principal)
Age, Gender	Num. / Cat.	Edad en años; sexo (F/M)	Riesgo y auditoría de equidad
Scholarship	Binaria	Beneficiario de Bolsa Família (proxy socioeconómico)	Riesgo y equidad
Hipertension, Diabetes, Alcoholism, Handcap	Binaria / 0–4	Condiciones registradas; Handcap = n.º de discapacidades	Comorbilidad (sensible)
SMS_received	Binaria	Se envió al menos un SMS de recordatorio	Intervención evaluable
Neighbourhood	Cat. (81)	Barrio de la unidad de atención	Contexto territorial
No-show	Binaria	Yes = no asistió (variable objetivo)	Objetivo

6. Entendimiento y calidad de los datos

Calidad. Completitud total (0 nulos) y unicidad de cita_id. Se detectaron: 5 citas con fecha anterior al agendamiento y 1 edad negativa (excluidas, 6 registros); 7 edades > 100 (marcadas para validar); Handcap codificado 0–4 y no binario (199 casos); 618 registros idénticos salvo el ID (posible doble agendamiento, a revisar con el stakeholder); y la fecha de la cita **no tiene hora**, lo que impide modelar la franja horaria. **Univariado:** la antelación es muy asimétrica (mediana 4 días, asimetría 2,67; 34,9 % se agenda el mismo día); 60,9 % de los pacientes tiene una sola cita (máximo 88), y 32,1 % recibió SMS.

Fig. 2. Tasa de inasistencia por variable (línea = tasa global)

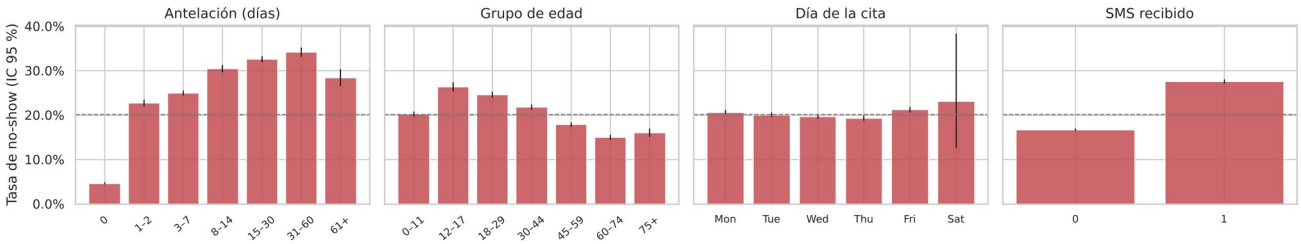


Figura 2. Tasa de inasistencia (IC 95 % de Wilson) por antelación, edad, día y SMS. Línea punteada = tasa global.

Bivariado. La antelación es la variable con mayor tamaño de efecto (r rank-biserial = 0,40): la inasistencia pasa de 4,6 % en citas del mismo día a 30,5 %–34,2 % cuando se agenda con 8 a 60 días. La edad muestra un gradiente inverso (máximo en 12–17 años, 26,4 %). Sexo (p = 0,17) y día de la semana tienen efectos despreciables (V < 0,02).

Multivariado. El SMS parece *aumentar* la inasistencia (OR crudo = 1,90), pero solo se envía a citas con ≥ 3 días de antelación, que de por sí tienen más riesgo: al estratificar por días de antelación el efecto se invierte (**OR de Mantel-Haenszel = 0,77 [0,74–0,80]**), una paradoja de Simpson que justifica focalizar recordatorios. En el modelo logístico ajustado, el historial de inasistencias (OR = 1,44 [IC 95 %: 1,36–1,52]), el subsidio, la edad y la antelación son los efectos independientes más robustos; la tasa sube de 13,5 % sin inasistencias previas a 35,6 % con 3 o más. 11 de 81 barrios se salen de los límites del 99,8 % del funnel plot (variación territorial real).

Fig. 3. Análisis multivariado

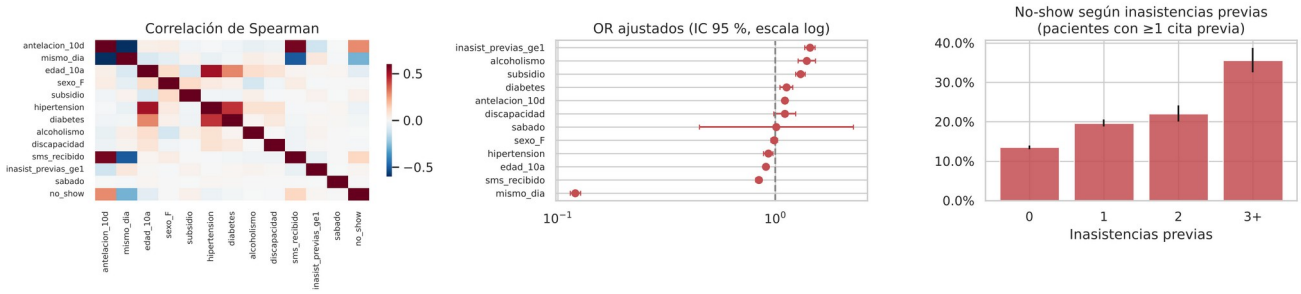


Figura 3. Correlaciones de Spearman, OR ajustados (IC 95 %) y tasa según inasistencias previas sin fuga temporal.

Suficiencia. Una línea base sin optimizar (validación cruzada agrupada por paciente, k = 5) alcanza ROC-AUC = 0,715 con regresión logística y 0,733 ± 0,004 con gradient boosting e historial; PR-AUC = 0,364 (1,8 veces la prevalencia) y Brier = 0,144 (vs. 0,161 de predecir la prevalencia). Al construir el historial se corrigió una fuga temporal (contar citas agendadas antes pero aún no ocurridas), que inflaba el ROC-AUC en ≈ 0,01. La señal es **suficiente para priorizar, pero moderada**: faltan servicio, hora, profesional, distancia y cancelaciones previas, que se solicitarán a MinHalma. Detalle: notebooks/01_eda_calidad.ipynb.

7. Conclusiones iniciales y próximos pasos

- **La antelación es la palanca operativa principal:** confirmar activamente en D-3/D-1 las citas agendadas con 8 a 60 días de antelación, donde la inasistencia supera el 30 %.
- **Los recordatorios funcionan si se mide bien:** ajustado por antelación, el SMS reduce las odds de inasistencia ≈ 23 %; la comparación cruda lleva a la conclusión opuesta.
- **Focalizar es viable:** contactar el 30 % de citas de mayor riesgo capturaría ≈ 53 % de las inasistencias, frente al 30 % esperado al azar.
- **Equidad como requisito de diseño:** jóvenes y beneficiarios de subsidio presentan más riesgo; el modelo debe ampliar el apoyo a estos grupos, no restringir su acceso.
- **Acciones siguientes:** formalizar el acuerdo de datos y el aval ético con MinHalma (interacción 1 de la bitácora); replicar el EDA con datos reales; en la Entrega 2, preparar datos, entrenar y comparar ≥ 3 algoritmos, y desplegar API y dashboard.

Referencias

Blu Radio. (2025, 15 de julio). Preocupación por inasistencia a más de 15.000 citas médicas en hospital de San Gil. https://www.bluradio.com/regiones/santanderes/preocupacion-por-inasistencia-a-mas-de-15-000-citas-medicas-en-hospital-de-san-gil-rg10

Congreso de Colombia. (1979). Ley 73 de 1979, por la cual se reglamenta la profesión de nutricionista-dietista.

Congreso de Colombia. (1999). Ley 528 de 1999, por la cual se reglamenta el ejercicio de la profesión de fisioterapia.

Congreso de Colombia. (2006). Ley 1090 de 2006, por la cual se reglamenta el ejercicio de la profesión de Psicología.

Congreso de Colombia. (2012). Ley Estatutaria 1581 de 2012, por la cual se dictan disposiciones generales para la protección de datos personales.

Congreso de Colombia. (2013). Ley 1616 de 2013, por medio de la cual se expide la ley de salud mental.

Congreso de Colombia. (2020). Ley 2015 de 2020, por medio de la cual se crea la historia clínica electrónica interoperable.

Consejo Nacional de Política Económica y Social. (2019). Documento CONPES 3975: Política nacional para la transformación digital e inteligencia artificial. DNP.

Dantas, L. F., Fleck, J. L., Cyrino Oliveira, F. L., & Hamacher, S. (2018). No-shows in appointment scheduling – a systematic literature review. Health Policy, 122(4), 412–421. https://doi.org/10.1016/j.healthpol.2018.02.002

Hoppen, J. (2016). Medical Appointment No Shows [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/joniarroba/noshowappointments

Ministerio de Salud. (1993). Resolución 8430 de 1993, normas científicas, técnicas y administrativas para la investigación en salud.

Ministerio de Salud. (1999). Resolución 1995 de 1999, normas para el manejo de la historia clínica.

Obermeyer, Z., Powers, B., Vogeli, C., & Mullainathan, S. (2019). Dissecting racial bias in an algorithm used to manage the health of populations. Science, 366(6464), 447–453. https://doi.org/10.1126/science.aax2342

Presidencia de la República de Colombia. (2013). Decreto 1377 de 2013, por el cual se reglamenta parcialmente la Ley 1581 de 2012.

Salazar, L. H. A., Leithardt, V. R. Q., Parreira, W. D., da Rocha Fernandes, A. M., Barbosa, J. L. V., & Correia, S. D. (2022). Application of machine learning techniques to predict a patient's no-show in the healthcare sector. Future Internet, 14(1), 3. https://doi.org/10.3390/fi14010003

Valora Analitik. (2026, 20 de abril). Calidad de la salud empeoró en 2025 y los colombianos asisten cada vez menos a citas médicas. https://www.valoraanalitik.com/calidad-de-la-salud-empeoro-en-2025-y-los-colombianos-asisten-cada-vez-menos-a-citas-medicas/